UNIVERSIDADE ESTADUAL DE CAMPINAS (UNICAMP)

Faculdade de Engenharia Elétrica e de Computação (FEEC)

Proposta preliminar: Otimização da localização de infraestrutura de recarga para veículos elétricos

Abordagem via Programação Linear Inteira Mista (MILP) com mitigação de canibalização espacial

Pesquisadores:

Núbia Sidene Almeida das Virgens

Doutoranda em Engenharia Elétrica e de Computação

Carlos Julian Muñoz Quiroga

Doutorando em Engenharia Elétrica e de Computação

Orientado por:

Prof. Dr. Romis Ribeiro de Faissol Attux

Repositório do protótipo e modelo:

Primeira-proposta-MILP

Campinas, SP

31 de março de 2026

Sumário

1 Introdução e contexto do problema **2**
1.1 Pré-requisitos do sistema 2
1.1.1 Python 3.10 2
1.1.2 IBM ILOG CPLEX Optimization Studio 2
1.2 Configuração do ambiente 2
1.3 Execução da ferramenta 3
1.4 Estrutura de arquivos 3
1.5 Solução de problemas comuns 3

2 Arquitetura de pré-processamento e simulação espacial **5**
2.1 Geração de candidatos e atratividade gravitacional base 5
2.2 Concorrência existente e decaimento espacial 5
2.3 Canibalização potencial e a matriz de cenários 6
2.4 Mapeamento de cobertura (*Set-Covering*) 6

3 Modelo matemático de otimização (MILP) **7**
3.1 Conjuntos 7
3.2 Parâmetros 7
3.2.1 Lucro e Atratividade (pré-computados via simulador espacial) . . . 7
3.2.2 Qualidade de rede 8
3.3 Variáveis de decisão 8
3.4 Função objetivo 8
3.5 Restrições 8
3.5.1 Grupo 1: Linearização e Configuração de Vizinhos 8
3.5.2 Grupo 2: Qualidade Global de Rede (Considerando Infraestrutura Existente) 8

4 Limitações e extensões futuras **10**

1 Introdução e contexto do problema

Este guia orienta a configuração e utilização da ferramenta de otimização de forma direta e autônoma.

1.1 Pré-requisitos do sistema

Para executar esta ferramenta, seu ambiente deve atender a dois requisitos fundamentais:

1.1.1 Python 3.10

Verifique se o Python está instalado abrindo o *Prompt de Comando* (cmd) e digitando:

```
py --list
```

Como interpretar:

- Se aparecer `- 3.10.X` (ou superior), o Python está pronto.
- Se der erro, baixe o instalador em `python.org` e marque a opção "Add to PATH"durante a instalação.

1.1.2 IBM ILOG CPLEX Optimization Studio

O modelo utiliza a biblioteca `docplex`, que requer o motor de otimização da IBM instalado no sistema.

- É obrigatório ter uma instalação do CPLEX com licença acadêmica ou comercial.
- Não utilize a versão "Community Edition", ela possui limites restritos de variáveis e restrições que são insuficientes para a complexidade deste case, impedindo a resolução.

1.2 Configuração do ambiente

Este passo é necessário apenas na primeira vez que você for usar a ferramenta. Localize e execute o arquivo `criar_ambiente.bat` na pasta raiz do projeto.

- Uma janela do terminal se abrirá e instalará automaticamente as dependências.
- Aguarde até ver a mensagem "AMBIENTE CRIADO COM SUCESSO"e feche a janela.
- Se a janela fechar instantaneamente sem mensagens de sucesso, verifique sua instalação do Python.

1.3 Execução da ferramenta

Para utilizar o otimizador no dia a dia:

1. Execute o arquivo `executar_solver.bat` na pasta raiz.
2. Uma janela de seleção de arquivos abrirá automaticamente. Selecione a planilha Excel com os dados de entrada.
3. Acompanhe o progresso no terminal. O solver processará os dados e buscará a melhor solução.
4. Ao finalizar, a ferramenta abrirá automaticamente a planilha de resultados gerada na pasta `resultados`.

Controle de Execução (Importante):
O solver foi configurado para buscar a solução ótima sem um limite de tempo pré-fixado.

- **Interrupção manual:** Você pode interromper o processo a qualquer momento pressionando o atalho `Ctrl + C` na janela do terminal.
- **Salvamento automático:** Ao interromper o processo, o programa salvará automaticamente a melhor solução encontrada até aquele instante, garantindo que nenhum progresso válido seja perdido.

1.4 Estrutura de arquivos

A organização das pastas do projeto segue o padrão abaixo. Mantenha essa estrutura para garantir o funcionamento dos scripts automáticos.

```
desafio-otimizacao-suzano/
|
+-- criar_ambiente.bat          (Configuracao inicial)
+-- executar_solver.bat         (Execucao diaria)
+-- requirements.txt            (Lista de dependencias)
|
+-- code/                       (Codigos-fonte Python)
|   +-- modelo.py
|   +-- gestor_dados.py
|   +-- exportar_resultados.py
|
+-- venv/                       (Gerado automaticamente)
+-- resultados/                 (Gerado automaticamente)
```

1.5 Solução de problemas comuns

- **Erro "Python não encontrado"ou comando "py"inválido:** O Python não está instalado corretamente. Reinstale marcando a opção "Add to PATH".

- **Erro "Ambiente não encontrado":** A pasta `venv` pode ter sido deletada. Execute novamente o arquivo `criar_ambiente.bat`.
- **Erro "Arquivo não encontrado":** Certifique-se de executar os arquivos `.bat` sempre a partir da pasta raiz do projeto, e não de dentro das subpastas.

Nota de portabilidade: Esta ferramenta é portável. Para usá-la em outro computador, basta copiar a pasta inteira do projeto e rodar o `criar_ambiente.bat` no novo local.

2 Arquitetura de pré-processamento e simulação espacial

A formulação de um problema de localização espacial com interações de mercado (canibalização de demanda) apresenta um desafio inerente: a não-linearidade. Se a atratividade de um novo eletroposto depende de quais outros eletropostos vizinhos serão abertos simultaneamente, a função objetivo original assumiria uma forma bilineal, tornando o problema intratável para solvers exatos em instâncias de grande porte.

Para contornar este obstáculo e garantir uma arquitetura puramente linear (MILP), esta proposta adota uma etapa rigorosa de pré-processamento e simulação espacial. Todo o esforço computacional não-linear é isolado nesta fase, que transforma a topologia urbana em um conjunto de parâmetros fixos que alimentarão o otimizador.

Esta etapa é dividida em quatro fases principais:

2.1 Geração de candidatos e atratividade gravitacional base

A área de estudo é inicialmente dividida em uma malha virtual. Para cada quadrante, os Pontos de Interesse (POIs) – categorizados e ponderados segundo seu potencial de geração de viagens (ex: supermercados, hospitais, shopping centers) – são mapeados utilizando dados de geolocalização.

O centroide matemático de cada quadrante é calculado e, para garantir o realismo da infraestrutura, aplica-se uma técnica de *Snap to Road* (Ajuste à via). Esta técnica utiliza *Reverse Geocoding* para deslocar o centroide teórico (que poderia recair sobre corpos d'água ou propriedades privadas) para a via pública trafegável mais próxima. Este ponto ajustado torna-se um **nó candidato** para a instalação de um eletroposto.

Nesta fase, calcula-se a **Atratividade Base** de cada candidato, que representa a demanda potencial que o local capturaria se operasse como um monopólio isolado.

2.2 Concorrência existente e decaimento espacial

Um modelo realista não pode ignorar a infraestrutura de recarga já consolidada na cidade. A presença de um eletroposto concorrente próximo reduz a fração de demanda capturável por um novo candidato.

Para modelar essa interação, implementou-se uma função de **Decaimento Espacial** baseada na distância real de roteamento (estimada via distância de Haversine com fator de tortuosidade urbana). O modelo estabelece três zonas de impacto para penalizar a atratividade de um candidato:

- **Zona de Impacto Total (Zona Vermelha):** Se um concorrente está demasiadamente próximo (ex: raio inferior a 300 metros), assume-se sobreposição severa de mercado, aplicando-se a penalidade máxima definida.

- **Zona de Transição:** Para distâncias intermediárias (ex: entre 300 e 1500 metros), a penalidade decai linearmente, reduzindo o impacto à medida que os postos se distanciam.

- **Zona Livre:** Se a distância supera o limite máximo de influência (ex: acima de 1500 metros), o concorrente é desconsiderado, assumindo-se impacto nulo.

Ao subtrair as penalidades dos concorrentes reais da Atratividade Base (e descontando uma barreira de custo operacional/viabilidade mínima), obtém-se o **Retorno Líquido Próprio** do candidato.

2.3 Canibalização potencial e a matriz de cenários

A inovação central deste pré-processamento reside no tratamento da concorrência entre os próprios nós candidatos. Como ainda não se sabe quais candidatos serão abertos pelo modelo, calcula-se previamente o impacto de *todas as combinações possíveis*.

Para um dado candidato, o algoritmo identifica seus vizinhos potenciais dentro do raio de influência. Para evitar uma explosão combinatória, restringe-se a análise aos K vizinhos mais impactantes (ex: os 4 ou 5 mais próximos). Em seguida, o simulador gera uma tabela exaustiva contendo o retorno líquido do candidato para todos os cenários de operação de seus vizinhos (2^K configurações).

Este "menu de retornos"pré-calculado é o que permite ao modelo matemático (Seção 3) realizar escolhas de forma puramente linear, apenas selecionando o cenário correspondente à decisão topológica.

2.4 Mapeamento de cobertura (*Set-Covering*)

A última etapa do pré-processamento garante os insumos para as métricas de qualidade de rede. O modelo exige que uma porcentagem mínima de todos os POIs da região tenha acesso a pelo menos um eletroposto a uma distância caminhável aceitável (ex: 800 metros, ou cerca de 10 minutos de caminhada).

O simulador realiza uma varredura bidirecional:

1. **Cobertura consolidada:** Identifica todos os POIs que já estão a menos da distância caminhável de um eletroposto real existente. Estes são marcados como "atendidos"e isolados, evitando esforços redundantes do modelo.

2. **Mapeamento de viabilidade:** Para os POIs restantes (desassistidos), o sistema mapeia quais nós candidatos têm a capacidade geométrica de cobri-los.

Este mapeamento previne o problema estatístico de *dupla contagem* – garantindo que se dois eletropostos novos cobrirem o mesmo supermercado, a métrica global de cobertura contabilizará o benefício apenas uma vez.

3 Modelo matemático de otimização (MILP)

3.1 Conjuntos

- C: Conjunto de locais candidatos para instalação de novos eletropostos.
- E: Conjunto de eletropostos concorrentes já existentes na malha urbana.
- P: Conjunto total de Pontos de Interesse (POIs) – hospitais, educação, transporte, comércio.
- $P_{\text{cob}} \subseteq P$: Subconjunto de POIs já atendidos (cobertos) por pelo menos um eletroposto existente $e \in E$.
- $P_{\text{ncob}} = P \setminus P_{\text{cob}}$: Subconjunto de POIs não atendidos, que dependem das decisões de instalação em C.
- $V(c)$: Conjunto de vizinhos espaciais do candidato c (dentro do raio crítico de influência).
- $\mathcal{S}_c$: Conjunto de todas as combinações possíveis de vizinhos de c que podem ser designados simultaneamente ($\mathcal{S}_c \subseteq 2^{V(c)}$).

3.2 Parâmetros

3.2.1 Lucro e Atratividade (pré-computados via simulador espacial)

- A_c: Atratividade gravitacional base do candidato c (Score derivado dos POIs próximos).
- B: Barreira de viabilidade (custo fixo mínimo ou atratividade mínima requerida para operação neutra).
- Π_c: Penalidade aplicada à atratividade do candidato c devido à proximidade (sobreposição de áreas de influência) com eletropostos já existentes $e \in E$.
- $R_c^{\text{próprio}}$: Retorno líquido do eletroposto c se operasse sem novos vizinhos, mas **sujeito à concorrência existente**. Definido como:

$$R_c^{\text{próprio}} = A_c - B - \Pi_c \tag{1}$$

- $\Delta R_{c,c'}$: Retorno (demanda) desviado do candidato c para seu vizinho $c' \in V(c)$ quando c' é designado. Representa a canibalização espacial entre as novas opções, calculada com base na distância de decaimento pela malha viária.
- $R_c(S_c)$: Retorno esperado do candidato c quando exatamente o conjunto de vizinhos $S_c \subseteq V(c)$ está designado. Definido como:

$$R_c(S_c) = R_c^{\text{próprio}} - \sum_{c' \in S_c} \Delta R_{c,c'} \tag{2}$$

3.2.2 Qualidade de rede

- $Q_{\text{min}}^{\text{cob}}$: Cobertura mínima da totalidade de POIs requerida na cidade (percentual, ex: 85%).
- r_{cob}: Raio de cobertura máximo aceitável pela malha viária para um POI ser considerado atendido (metros).

3.3 Variáveis de decisão

- $x_c \in \{0, 1\}$: Indicadora – designar a instalação de um eletroposto no candidato c.
- $y_p \in \{0, 1\}$: Indicadora – POI $p \in P_{\text{ncob}}$ passa a ser coberto por pelo menos um *novo* eletroposto designado.
- $z_{c,S_c} \in \{0, 1\}$: Indicadora – a configuração exata de vizinhos *novos* designados para o eletroposto c é o conjunto S_c.

3.4 Função objetivo

$$\max \quad Z = \sum_{c \in C} \sum_{S_c \in \mathcal{S}_c} R_c(S_c) \cdot z_{c,S_c} \tag{3}$$

Nota: O objetivo maximiza o retorno líquido global, selecionando a configuração de concorrência real (z_{c,S_c}) que a rede terminará enfrentando após as designações.

3.5 Restrições

3.5.1 Grupo 1: Linearização e Configuração de Vizinhos

R1: Atribuição única de configuração

$$\sum_{S_c \in \mathcal{S}_c} z_{c,S_c} = x_c \quad \forall c \in C \tag{4}$$

R2: Consistência lógica de designações

Se a configuração S_c for a escolhida ($z_{c,S_c} = 1$), os vizinhos correspondentes devem estar obrigatoriamente designados ou desligados:

$$x_{c'} \geq z_{c,S_c} \quad \forall c \in C, \forall S_c \in \mathcal{S}_c, \forall c' \in S_c \tag{5}$$

$$x_{c'} \leq 1 - z_{c,S_c} \quad \forall c \in C, \forall S_c \in \mathcal{S}_c, \forall c' \in V(c) \setminus S_c \tag{6}$$

3.5.2 Grupo 2: Qualidade Global de Rede (Considerando Infraestrutura Existente)

R3: Indicador de nova cobertura para POIs desassistidos

$$y_p \leq \sum_{c \in C : \text{dist}(c,p) \leq r_{\text{cob}}} x_c \quad \forall p \in P_{\text{ncob}} \tag{7}$$

Um POI desassistido p só será contabilizado como coberto ($y_p = 1$) se pelo menos um novo candidato em seu raio de alcance for instalado.

R4: Meta integrada de cobertura mínima

$$|P_{\text{cob}}| + \sum_{p \in P_{\text{ncob}}} y_p \geq \lceil Q_{\min}^{\text{cob}} \cdot |P| \rceil \tag{8}$$

A quantidade de POIs cobertos gratuitamente pela infraestrutura existente ($|P_{\text{cob}}|$) somada aos POIs resgatados pela nova infraestrutura deve atender ou superar o volume mínimo exigido pelo planejamento urbano.

4 Limitações e extensões futuras

A arquitetura proposta neste relatório estabelece uma base matemática sólida e computacionalmente eficiente para a localização de infraestrutura de recarga de veículos elétricos (EVCS). O isolamento das não-linearidades em uma etapa prévia de simulação espacial permite que o otimizador MILP opere com máxima performance.

Contudo, como toda abstração da realidade urbana, o modelo atual apresenta premissas simplificadoras. Para as próximas etapas desta pesquisa de doutorado, propõe-se a expansão do modelo através das seguintes frentes de desenvolvimento:

4.1 Refinamento dos parâmetros de concorrência e demanda

Atualmente, o decaimento espacial e a canibalização são governados estritamente pela distância viária. Embora robusta, essa abordagem pode ser enriquecida:

- **Heterogeneidade da infraestrutura:** Incorporar metadados detalhados dos eletropostos (ex: quantidade de conectores, potência máxima em kW, tipos de plugue). Um eletroposto ultrarrápido (150 kW) exerce uma força de atração gravitacional e uma penalidade de concorrência significativamente maiores do que um carregador de parede (7 kW).

- **Modelos de escolha discreta (*Logit/Probit*):** Substituir o decaimento linear da Zona de Transição por modelos probabilísticos de comportamento do consumidor, estimando a probabilidade real de um usuário desviar sua rota para um posto específico.

4.2 Expansão do modelo de otimização (MILP)

A estrutura puramente linear do modelo atual (3) permite a adição de novas restrições sem comprometer a viabilidade computacional. As principais extensões previstas incluem:

- **Restrição de orçamento global (CAPEX):** Implementar uma inequação que limite o número de nós selecionados (x_c) ao orçamento de capital disponível, forçando o solver a priorizar os candidatos de mais alta eficiência marginal ($\sum c_c \cdot x_c \leq B$).

- **Capacitação da rede elétrica:** Integrar restrições físicas da rede de distribuição. O modelo deve evitar a alocação de múltiplos eletropostos de alta potência em um mesmo alimentador local que não possua capacidade de carga ociosa suficiente, prevenindo instabilidades na rede.

- **Formulação multi-período:** Expandir o vetor de decisão para contemplar o horizonte temporal de adoção de VEs ($x_{c,t}$). O modelo não apenas decidirá *onde* instalar, mas *quando* instalar cada estação ao longo de uma década, acompanhando a curva projetada de demanda.

4.3 Otimização robusta e incerteza

Os dados de Ponto de Interesse (POI) representam uma fotografia estática da demanda urbana. No entanto, o tecido urbano é dinâmico. Trabalhos futuros poderão aplicar técnicas de **Otimização Robusta** para lidar com a incerteza nos parâmetros de atratividade

(A_c). O objetivo será encontrar uma rede de eletropostos que mantenha um desempenho satisfatório e garanta a meta de cobertura ($Q_{\min}^{\text{cob}}$) mesmo sob os piores cenários de projeção de demanda ou falhas parciais na rede concorrente.

O desenvolvimento iterativo destas extensões não apenas aumentará a fidelidade do modelo frente à realidade operacional das cidades inteligentes, mas também consolidará a contribuição científica desta tese para a área de Pesquisa Operacional aplicada à mobilidade elétrica.